




# UD03: Procesamiento del Lenguaje Natural

Modelos de Inteligencia Artificial

version: 2026-08-24

# ¿Qué veremos?

1. Qué es el PLN
2. El potencial, con cifras
3. La ambigüedad
4. Desambiguación y POS *tagging*
5. Las demás limitaciones
6. Cuándo es factible: la lupa del AI Act
7. Quién hace un proyecto de PLN
8. Las herramientas en Python
9. Construir un sistema orientado a una tarea

## RA3 y sus criterios de evaluación

“ **RA3** — Relaciona el PLN con sus aplicaciones, su potencial y sus limitaciones. ”

| CE       | Criterio                   | Dónde  |
|----------|----------------------------|--------|
| <b>a</b> | Caracterizar el PLN        | §1, §4 |
| <b>b</b> | Papel del lingüista        | §7     |
| <b>c</b> | Potencial y limitaciones   | §2-5   |
| <b>d</b> | Cuándo es factible         | §6     |
| <b>e</b> | Trabajo cooperativo        | §7     |
| <b>f</b> | Formación del investigador | §7     |
| <b>g</b> | Elaborar un sistema        | §8-9   |

**Siete criterios:** los más de todo el módulo.

## Al terminar la unidad serás capaz de...

- **Explicar** qué es el PLN y situarlo entre lingüística e informática.
- **Distinguir** los seis tipos de ambigüedad en frases reales.
- **Explicar** cómo el etiquetado POS desambigua, y qué cuesta elegir el conjunto de etiquetas.
- **Determinar** cuándo es factible aplicar PLN, con el AI Act.
- **Justificar** el papel del lingüista y **evaluar** la cooperación con informáticos.
- **Usar** `nltk` y spaCy para tareas básicas en español.
- **Construir y evaluar** un sistema de PLN orientado a una tarea.

# 1. Qué es el PLN

RA3-a

# Tres disciplinas, un campo

| Disciplina                | Qué aporta                                            |
|---------------------------|-------------------------------------------------------|
| Lingüística computacional | Modelos del lenguaje: morfología, sintaxis, semántica |
| Estadística y ML          | Aprender patrones de los textos                       |
| Aprendizaje profundo      | Representaciones del lenguaje ( <i>transformers</i> ) |

**No es magia:** se procesa **estadísticamente**, no se «entiende» como una persona.

# Los niveles del lenguaje

| Nivel              | Analiza                 | Tarea de PLN                               |
|--------------------|-------------------------|--------------------------------------------|
| Fonética/fonología | Sonidos                 | ASR, TTS                                   |
| Morfología         | Estructura de palabras  | <i>Stemming</i> , lematización, <b>POS</b> |
| Sintaxis           | Estructura de oraciones | Análisis sintáctico                        |
| Semántica          | Significado             | Desambiguación, entidades                  |
| Pragmática         | Según contexto          | Correferencia, sentimiento                 |

Hay ambigüedad en **todos** los niveles: es el mapa del bloque 3.

# Las tareas del PLN

| Tarea                           | Ejemplo                           |
|---------------------------------|-----------------------------------|
| Tokenización                    | «Hola mundo» → [«Hola», «mundo»]  |
| Etiquetado POS                  | «correr» → verbo                  |
| Entidades (NER)                 | «María vive en Madrid» → PER, LOC |
| Sentimiento                     | «¡Genial!» → positivo             |
| Traducción, resumen, generación | —                                 |
| Respuesta a preguntas           | Asistentes, buscadores            |



# El *pipeline*, siempre igual

Texto → Preprocesado → Representación → Modelo → Salida  
tokenizar, BoW, tf-idf, ML o red clasificación,  
minúsculas, embeddings profunda entidades...  
stopwords

El corrector, el buscador y el asistente de voz son los mismos cuatro pasos.

# 2. El potencial

RA3-c

## Qué se consigue hoy

| Aplicación                    | Estado                                    |
|-------------------------------|-------------------------------------------|
| Buscadores, asistentes de voz | Entienden, extraen entidades, responden   |
| Traducción automática         | Calidad funcional en tiempo real          |
| Análisis de opinión           | Miles de reseñas, automático              |
| Extracción de información     | Facturas y contratos, sin tocarlos a mano |
| Modelos generativos           | Redactar, resumir, traducir               |

# Tres cifras para calibrar

- **SQuAD 2.0**: los mejores sistemas **superan la precisión humana** (EM ~91 frente a ~87).
- Sentimiento en IMDb: de ~89 % (2011) a **95-97 %** con *transformers*.
- Hugging Face: más de **2 millones de modelos**, 500.000 *datasets*.

# Los modelos de uso general

El **AI Act** los define:  $\geq$  **1.000 millones de parámetros**, autosupervisión a gran escala, competentes en muchas tareas. Los LLM son el ejemplo típico.

**Capacidades de gran impacto:** cuando el cómputo del entrenamiento supera  **$10^{25}$  FLOPS** (art. 51.2) → documentación y evaluación adicionales. Se ve a fondo en la UD06.

# **3. La ambigüedad el problema de fondo**

**RA3-c**

## Seis tipos

| Tipo                        | Cuándo aparece                        |
|-----------------------------|---------------------------------------|
| <b>Sintáctica</b>           | Más de un análisis gramatical posible |
| <b>Léxica / morfológica</b> | Un término admite varias lecturas     |
| <b>Semántica</b>            | Un elemento tiene varios sentidos     |
| <b>Pragmática</b>           | Depende del contexto y de quién habla |
| <b>Fonológica</b>           | Una cadena de sonidos confunde        |
| <b>Funcional</b>            | Doble función gramatical              |

## Los seis, con frases reales

- **Sintáctica** — «*Compro los libros baratos*»: ¿los baratos, o libros que además son baratos?
- **Léxica** — «*Usted aquí no pinta nada*»: ¿mando, o pintar una pared?
- **Semántica** — «*Pedro quiere pelearse con un italiano*»: ¿cualquiera, o uno concreto?
- **Pragmática** — «*Golpeó el armario con el bastón y lo rompió*»: ¿qué se rompió?
- **Fonológica** — «*es-conde*»: ¿esconder, o «es» + «conde»?
- **Funcional** — «*He vuelto a oler*»: ¿recuperé el olfato, o regresé a oler algo?



# Un banco de frases para probar cualquier sistema

- El cura recibió una cura en su habitación.
- Antonio no nada nada.
- No puedo ir a la fiesta porque no traje traje.
- El Villarreal le ganó al Valencia en su campo.
- Me quedé esperándote en el banco.

Casi todas se resuelven **con el contexto**, no con la frase.

# No se arregla: se decide

La ambigüedad **no es un error** del lenguaje: es una propiedad, y además útil.

**Forma  $\neq$  significado** (Bender y Koller): un modelo entrenado solo con la forma **no tiene forma *a priori*** de aprender el significado. Aprende correlaciones, no comprensión.

Por eso un modelo generativo puede sonar impecable **y** estar equivocado.

# 4. Desambiguación y POS

RA3-a, RA3-c

# El mismo «sobre», tres categorías

- «*Mételo en ese **sobre***» → **nombre**
- «*Déjalo **sobre** la mesa*» → **preposición**
- «*Dame lo que te **sobre***» → **verbo**

Ningún diccionario resuelve esto: hace falta el **contexto**. Es el primer paso de casi todo lo demás.

## Elegir el *tagset*: un compromiso

Más etiquetas = **más información** y **más difícil acertar**.

| <i>Tagset</i>   | Etiquetas |
|-----------------|-----------|
| Penn Treebank   | 45        |
| Brown Corpus    | 87        |
| LexEsp (PAROLE) | ~250      |
| Susanne         | 350       |

Categorías **abiertas** (nombres, verbos) admiten palabras nuevas; **cerradas** (preposiciones), no.

# Por qué esto es del lingüista

Decidir el *tagset* y escribir la guía de anotación **no es programación**: es lingüística aplicada, y condiciona **todo** lo que el modelo puede aprender después.

Es el ejemplo más concreto del **RA3-b**.

# Cómo se etiqueta

| Enfoque          | Cómo                          | Dónde                                       |
|------------------|-------------------------------|---------------------------------------------|
| <b>Reglas</b>    | A mano, sobre el contexto     | Dominios muy acotados                       |
| <b>HMM / TnT</b> | Probabilidad de una secuencia | <code>cess_esp</code> con <code>nltk</code> |
| <b>Neuronal</b>  | Con el contexto completo      | <i>spaCy, transformers</i>                  |

# 5. Las demás limitaciones

RA3-c



# Falta de comprensión real

Los modelos **generan sin comprender**: no verifican hechos, no razonan, pueden **alucinar** – inventar datos con total seguridad.

En cualquier tarea con consecuencias, **la salida se verifica**.

# Sesgos

- Sesgo de **género** en *embeddings*: «médico → hombre», «enfermera → mujer».
- Sesgos **raciales y culturales** en los datos de entrenamiento.
- El AI Act: pueden **perpetuarse y amplificarse** en bucles de retroalimentación.

**Prohibido:** inferir emociones **en el trabajo y en centros educativos**  
— base científica débil, uso discriminatorio.

# Lenguas con pocos recursos, e ironía

- Casi todo se entrena en **inglés**. En lenguas minoritarias, lo **estadístico clásico** puede ganar a lo neuronal.
- «*¡Qué buena idea, se me ha caído el móvil al agua!*»: literalmente positivo, pragmáticamente negativo. Los modelos fallan a menudo.

# **6. Cuándo es factible**

## **la lupa del AI Act**

### **RA3-d**

# Cinco criterios

| Criterio              | Pregunta guía                       |
|-----------------------|-------------------------------------|
| Tarea clara y acotada | ¿Qué salida exacta quiero?          |
| Datos disponibles     | ¿Hay textos suficientes y anotados? |
| Dominio conocido      | ¿Vocabulario acotado?               |
| Calidad realista      | ¿Acepto un 5-10 % de error?         |
| Regulación            | ¿Lo prohíbe o restringe el AI Act?  |

## Factible y no factible

| Factible hoy                               | Prohibido o no factible                         |
|--------------------------------------------|-------------------------------------------------|
| Clasificar documentos, detectar duplicados | <b>Inferir emociones</b> en trabajo o educación |
| Mejorar el registro de un texto            | Extracción no selectiva de rostros              |
| Traducción funcional                       | Manipulación subliminal                         |
| Análisis de sentimiento acotado            | Alto riesgo sin verificación                    |

**Considerando 53** (bajo riesgo) + **artículo 5** (prohibiciones) = lista de comprobación antes de construir.

# 7. Quién hace un proyecto de PLN

**RA3-b, RA3-e, RA3-f**

# Qué aporta el lingüista

| Aportación                         | Ejemplo                          |
|------------------------------------|----------------------------------|
| Anotar datos                       | Etiquetar entidades, sentimiento |
| Diseñar el <i>tagset</i> y la guía | El compromiso del bloque 4       |
| Recursos lingüísticos              | Corpus y <i>treebanks</i>        |
| Evaluar errores                    | Por qué falla el modelo          |

**Las anotaciones deciden las predicciones.** No se arregla con más datos.



## Cooperación: dos casos reales

- **Meta NLLB** (200 idiomas): hablantes nativos anotaron y evaluaron → **+44 % de BLEU**.
- **Masakhane** (PLN africano): 1.000+ participantes, 30 países. Los lingüistas locales son **investigadores**, no «solo anotadores». Rechazan la investigación **paracaidista**.

| Se gana                           | Cuesta                         |
|-----------------------------------|--------------------------------|
| Datos y evaluación mejores        | Vocabularios distintos         |
| Cobertura de lenguas minoritarias | Anotación lenta y cara         |
| Mejor ciencia                     | Riesgo de explotar comunidades |

# La formación del investigador

**Tres patas:** lingüística · estadística y ML · informática.

**Itinerario:** Jurafsky y Martin → NLTK → spaCy → *transformers*.

**Perfiles nuevos:** anotador especializado, *prompt engineer*, evaluador de sesgos. Todos parten de la misma base.

# Cómo se evalúan estos tres criterios

**No con un examen aparte:** con la **parte escrita** de **EX2** y **EX5**.

Se pide justificar qué decisiones tomaría un lingüista, qué aporta cada perfil y qué formación haría falta. **Está en la rúbrica, y cuenta.**

# 8. Las herramientas en Python

## RA3-c, RA3-g

# Dos entornos

- **Contenedor de la unidad:** `nltk`, spaCy, scikit-learn. Todo lo que no entrena redes grandes.
- **Colab:** `transformers`, entrenamiento, audio. Ahí hay GPU.

# NLTK, para entender

Transparente: cada paso, a mano.

```
tokens = word_tokenize(texto, language='spanish')  
sin_vacias = [t for t in tokens if t.lower() not in stopwords.words('spanish')]  
stem = SnowballStemmer('spanish').stem
```

**Pipeline:** tokenizar → limpiar *stopwords* → normalizar (*stemming* o lematización) → enriquecer (POS, entidades, frecuencias).

# spaCy, para producir

Un objeto `nlp`, todo el *pipeline* de una pasada:

Texto → Tokenizador → POS → Dependencias → Entidades → Lematizador

En una frase corriente, el analizador puede encontrar **miles de análisis posibles**: spaCy elige el más probable. La ambigüedad **no se elimina, se decide**.

**NLTK para aprender, spaCy para producir.**

# Sentimiento y *transformers*

- **scikit-learn** (tf-idf + regresión logística): funciona en español, sin GPU. Cuidado:  
`stop_words` solo acepta `'english'` — para español, una **lista**.
- **DistilBERT**: 40 % menos parámetros, 60 % más rápido, 97 % de la capacidad de BERT. El modelo de esta unidad, porque cabe en una sesión.



# 9. Construir un sistema orientado a una tarea

**RA3-g**

# Seis pasos

1. Definir la tarea → 2. Datos y licencia → 3. Elegir herramienta  
↓  
6. Documentar ← 5. Evaluar y analizar errores ← 4. Implementar

El paso que más se salta es el **5**: mirar los errores, no solo la métrica.

## La progresión de los notebooks

| Notebook | Construye                | Representación                 |
|----------|--------------------------|--------------------------------|
| N01      | Tokenizar, BoW, tf-idf   | Cuenta de palabras             |
| N02      | Clasificador con PyTorch | <i>Word embeddings</i>         |
| N03      | Afinar DistilBERT        | <i>Embeddings</i> contextuales |
| N04      | <i>Pipeline</i> de spaCy | Modelo preentrenado            |

Y los cinco entregables aplican cada nivel a un problema propio: **EX1** representación · **EX2** clasificador · **EX3** anotación · **EX4** *transfer learning* · **EX5** asistente de punta a punta.

# Ejemplo guiado: clasificador de reseñas

**1** clasificar positiva/negativa · **2** 60 reseñas anotadas · **3** tf-idf, no *transformer* · **4** `TfidfVectorizer` → `LogisticRegression` · **5** exactitud + leer 2 errores · **6** documentar origen y límites.

**La herramienta se elige por los datos que hay, no por lo moderna que sea.**

# Cierre

## Puntos clave (I)

- El PLN combina lingüística, estadística y aprendizaje profundo para que las máquinas comprendan y se comuniquen con el lenguaje humano.
- El potencial es alto y medible: SQuAD supera al humano, sentimiento al 95-97 %.
- La **ambigüedad** tiene seis formas y **no se elimina: se decide** con el contexto.
- El **POS tagging** desambigua categorías; el *tagset* es un compromiso información/dificultad.
- Sesgos, falta de comprensión, lenguas con pocos recursos e ironía son limitaciones reales.

## Puntos clave (II)

- El **AI Act** es una herramienta de diseño: bajo riesgo (considerando 53) y prohibiciones (artículo 5).
- El **lingüista** diseña el *tagset* y anota; **las anotaciones deciden las predicciones**.
- La **cooperación** se evalúa: NLLB y Masakhane frente a la investigación paracaidista.
- **NLTK para aprender, spaCy para producir**; la herramienta se elige por los datos que hay.
- Construir un sistema son **seis pasos**, y el que más se salta es **mirar los errores**.

## Cómo se evalúa

| Peso | Instrumento                                                       |
|------|-------------------------------------------------------------------|
| 40 % | Media de los <b>cinco entregables</b> ( EX1 - EX5 )               |
| 60 % | Prueba del RA3: test y desarrollo sobre el contenido de la unidad |

EX2 y EX5 llevan una **parte escrita** que cubre RA3-b, RA3-e y RA3-f. **Cuenta.**

La normativa exige alcanzar todos los RA; el centro lo concreta en  **$\geq 5$  en cada uno.**



# ¿Y ahora?

El lenguaje es la interfaz más natural entre personas y máquinas — y la más ambigua.

**A construir un sistema que la resuelva.**