




UD03: Procesamiento del Lenguaje Natural

Modelos de Inteligencia Artificial

version: 2026-08-23

¿Qué veremos?

1. Qué es el PLN
2. El potencial, con cifras
3. La ambigüedad
4. Desambiguación y POS *tagging*
5. Las demás limitaciones
6. Cuándo es factible: la lupa del AI Act
7. Quién hace un proyecto de PLN
8. Las herramientas en Python
9. Construir un sistema orientado a una tarea

RA3 y sus criterios de evaluación

“ **RA3** — Relaciona el PLN con sus aplicaciones, su potencial y sus limitaciones. ”

CE	Criterio	Dónde
a	Caracterizar el PLN	§1, §4
b	Papel del lingüista	§7
c	Potencial y limitaciones	§2-5
d	Cuándo es factible	§6
e	Trabajo cooperativo	§7
f	Formación del investigador	§7
g	Elaborar un sistema	§8-9

Siete criterios: los más de todo el módulo.

Al terminar la unidad serás capaz de...

- **Explicar** qué es el PLN y situarlo entre lingüística e informática.
- **Distinguir** los seis tipos de ambigüedad en frases reales.
- **Explicar** cómo el etiquetado POS desambigua, y qué cuesta elegir el conjunto de etiquetas.
- **Determinar** cuándo es factible aplicar PLN, con el AI Act.
- **Justificar** el papel del lingüista y **evaluar** la cooperación con informáticos.
- **Usar** `nltk` y spaCy para tareas básicas en español.
- **Construir y evaluar** un sistema de PLN orientado a una tarea.

1. Qué es el PLN

RA3-a

Tres disciplinas, un campo

Disciplina	Qué aporta
Lingüística computacional	Modelos del lenguaje: morfología, sintaxis, semántica
Estadística y ML	Aprender patrones de los textos
Aprendizaje profundo	Representaciones del lenguaje (<i>transformers</i>)

No es magia: se procesa **estadísticamente**, no se «entiende» como una persona.

Los niveles del lenguaje

Nivel	Analiza	Tarea de PLN
Fonética/fonología	Sonidos	ASR, TTS
Morfología	Estructura de palabras	<i>Stemming</i> , lematización, POS
Sintaxis	Estructura de oraciones	Análisis sintáctico
Semántica	Significado	Desambiguación, entidades
Pragmática	Según contexto	Correferencia, sentimiento

Hay ambigüedad en **todos** los niveles: es el mapa del bloque 3.

Las tareas del PLN

Tarea	Ejemplo
Tokenización	«Hola mundo» → [«Hola», «mundo»]
Etiquetado POS	«correr» → verbo
Entidades (NER)	«María vive en Madrid» → PER, LOC
Sentimiento	«¡Genial!» → positivo
Traducción, resumen, generación	—
Respuesta a preguntas	Asistentes, buscadores

El *pipeline*, siempre igual

Texto → Preprocesado → Representación → Modelo → Salida
tokenizar, BoW, tf-idf, ML o red clasificación,
minúsculas, embeddings profunda entidades...
stopwords

El corrector, el buscador y el asistente de voz son los mismos cuatro pasos.

2. El potencial

RA3-c

Qué se consigue hoy

Aplicación	Estado
Buscadores, asistentes de voz	Entienden, extraen entidades, responden
Traducción automática	Calidad funcional en tiempo real
Análisis de opinión	Miles de reseñas, automático
Extracción de información	Facturas y contratos, sin tocarlos a mano
Modelos generativos	Redactar, resumir, traducir

Tres cifras para calibrar

- **SQuAD 2.0**: los mejores sistemas **superan la precisión humana** (EM ~91 frente a ~87).
- Sentimiento en IMDb: de ~89 % (2011) a **95-97 %** con *transformers*.
- Hugging Face: más de **2 millones de modelos**, 500.000 *datasets*.

Los modelos de uso general

El **AI Act** los define: $\geq$ **1.000 millones de parámetros**, autosupervisión a gran escala, competentes en muchas tareas. Los LLM son el ejemplo típico.

Capacidades de gran impacto: cuando el cómputo del entrenamiento supera **10^{25} FLOPS** (art. 51.2) → documentación y evaluación adicionales. Se ve a fondo en la UD06.

3. La ambigüedad el problema de fondo

RA3-c

Seis tipos

Tipo	Cuándo aparece
Sintáctica	Más de un análisis gramatical posible
Léxica / morfológica	Un término admite varias lecturas
Semántica	Un elemento tiene varios sentidos
Pragmática	Depende del contexto y de quién habla
Fonológica	Una cadena de sonidos confunde
Funcional	Doble función gramatical

Los seis, con frases reales

- **Sintáctica** — «*Compro los libros baratos*»: ¿los baratos, o libros que además son baratos?
- **Léxica** — «*Usted aquí no pinta nada*»: ¿mando, o pintar una pared?
- **Semántica** — «*Pedro quiere pelearse con un italiano*»: ¿cualquiera, o uno concreto?
- **Pragmática** — «*Golpeó el armario con el bastón y lo rompió*»: ¿qué se rompió?
- **Fonológica** — «*es-conde*»: ¿esconder, o «es» + «conde»?
- **Funcional** — «*He vuelto a oler*»: ¿recuperé el olfato, o regresé a oler algo?

Un banco de frases para probar cualquier sistema

- El cura recibió una cura en su habitación.
- Antonio no nada nada.
- No puedo ir a la fiesta porque no traje traje.
- El Villarreal le ganó al Valencia en su campo.
- Me quedé esperándote en el banco.

Casi todas se resuelven **con el contexto**, no con la frase.

No se arregla: se decide

La ambigüedad **no es un error** del lenguaje: es una propiedad, y además útil.

Forma $\neq$ significado (Bender y Koller): un modelo entrenado solo con la forma **no tiene forma *a priori*** de aprender el significado. Aprende correlaciones, no comprensión.

Por eso un modelo generativo puede sonar impecable **y** estar equivocado.

4. Desambiguación y POS

RA3-a, RA3-c

El mismo «sobre», tres categorías

- «*Mételo en ese **sobre***» → **nombre**
- «*Déjalo **sobre** la mesa*» → **preposición**
- «*Dame lo que te **sobre***» → **verbo**

Ningún diccionario resuelve esto: hace falta el **contexto**. Es el primer paso de casi todo lo demás.

Elegir el *tagset*: un compromiso

Más etiquetas = **más información** y **más difícil acertar**.

<i>Tagset</i>	Etiquetas
Penn Treebank	45
Brown Corpus	87
LexEsp (PAROLE)	~250
Susanne	350

Categorías **abiertas** (nombres, verbos) admiten palabras nuevas; **cerradas** (preposiciones), no.

Por qué esto es del lingüista

Decidir el *tagset* y escribir la guía de anotación **no es programación**: es lingüística aplicada, y condiciona **todo** lo que el modelo puede aprender después.

Es el ejemplo más concreto del **RA3-b**.

Cómo se etiqueta

Enfoque	Cómo	Dónde
Reglas	A mano, sobre el contexto	Dominios muy acotados
HMM / TnT	Probabilidad de una secuencia	<code>cess_esp</code> con <code>nltk</code>
Neuronal	Con el contexto completo	<i>spaCy, transformers</i>

5. Las demás limitaciones

RA3-c

Falta de comprensión real

Los modelos **generan sin comprender**: no verifican hechos, no razonan, pueden **alucinar** – inventar datos con total seguridad.

En cualquier tarea con consecuencias, **la salida se verifica**.

Sesgos

- Sesgo de **género** en *embeddings*: «médico → hombre», «enfermera → mujer».
- Sesgos **raciales y culturales** en los datos de entrenamiento.
- El AI Act: pueden **perpetuarse y amplificarse** en bucles de retroalimentación.

Prohibido: inferir emociones **en el trabajo y en centros educativos**
— base científica débil, uso discriminatorio.

Lenguas con pocos recursos, e ironía

- Casi todo se entrena en **inglés**. En lenguas minoritarias, lo **estadístico clásico** puede ganar a lo neuronal.
- «*¡Qué buena idea, se me ha caído el móvil al agua!*»: literalmente positivo, pragmáticamente negativo. Los modelos fallan a menudo.

6. Cuándo es factible

la lupa del AI Act

RA3-d

Cinco criterios

Criterio	Pregunta guía
Tarea clara y acotada	¿Qué salida exacta quiero?
Datos disponibles	¿Hay textos suficientes y anotados?
Dominio conocido	¿Vocabulario acotado?
Calidad realista	¿Acepto un 5-10 % de error?
Regulación	¿Lo prohíbe o restringe el AI Act?

Factible y no factible

Factible hoy	Prohibido o no factible
Clasificar documentos, detectar duplicados	Inferir emociones en trabajo o educación
Mejorar el registro de un texto	Extracción no selectiva de rostros
Traducción funcional	Manipulación subliminal
Análisis de sentimiento acotado	Alto riesgo sin verificación

Considerando 53 (bajo riesgo) + **artículo 5** (prohibiciones) = lista de comprobación antes de construir.

7. Quién hace un proyecto de PLN

RA3-b, RA3-e, RA3-f

Qué aporta el lingüista

Aportación	Ejemplo
Anotar datos	Etiquetar entidades, sentimiento
Diseñar el <i>tagset</i> y la guía	El compromiso del bloque 4
Recursos lingüísticos	Corpus y <i>treebanks</i>
Evaluar errores	Por qué falla el modelo

Las anotaciones deciden las predicciones. No se arregla con más datos.

Cooperación: dos casos reales

- **Meta NLLB** (200 idiomas): hablantes nativos anotaron y evaluaron → **+44 % de BLEU**.
- **Masakhane** (PLN africano): 1.000+ participantes, 30 países. Los lingüistas locales son **investigadores**, no «solo anotadores». Rechazan la investigación **paracaidista**.

Se gana	Cuesta
Datos y evaluación mejores	Vocabularios distintos
Cobertura de lenguas minoritarias	Anotación lenta y cara
Mejor ciencia	Riesgo de explotar comunidades

La formación del investigador

Tres patas: lingüística · estadística y ML · informática.

Itinerario: Jurafsky y Martin → NLTK → spaCy → *transformers*.

Perfiles nuevos: anotador especializado, *prompt engineer*, evaluador de sesgos. Todos parten de la misma base.

Cómo se evalúan estos tres criterios

No con un examen aparte: con la **parte escrita** de **EX2** y **EX4**.

Se pide justificar qué decisiones tomaría un lingüista, qué aporta cada perfil y qué formación haría falta. **Está en la rúbrica, y cuenta.**

8. Las herramientas en Python

RA3-c, RA3-g

Dos entornos

- **Contenedor de la unidad:** `nltk`, spaCy, scikit-learn. Todo lo que no entrena redes grandes.
- **Colab:** `transformers`, entrenamiento, audio. Ahí hay GPU.

NLTK, para entender

Transparente: cada paso, a mano.

```
tokens = word_tokenize(texto, language='spanish')  
sin_vacias = [t for t in tokens if t.lower() not in stopwords.words('spanish')]  
stem = SnowballStemmer('spanish').stem
```

Pipeline: tokenizar → limpiar *stopwords* → normalizar (*stemming* o lematización) → enriquecer (POS, entidades, frecuencias).

spaCy, para producir

Un objeto `nlp`, todo el *pipeline* de una pasada:

Texto → Tokenizador → POS → Dependencias → Entidades → Lematizador

En una frase corriente, el analizador puede encontrar **miles de análisis posibles**: spaCy elige el más probable. La ambigüedad **no se elimina, se decide**.

NLTK para aprender, spaCy para producir.

Sentimiento y *transformers*

- **scikit-learn** (tf-idf + regresión logística): funciona en español, sin GPU. Cuidado:
`stop_words` solo acepta `'english'` — para español, una **lista**.
- **DistilBERT**: 40 % menos parámetros, 60 % más rápido, 97 % de la capacidad de BERT. El modelo de esta unidad, porque cabe en una sesión.

9. Construir un sistema orientado a una tarea

RA3-g

Seis pasos

1. Definir la tarea → 2. Datos y licencia → 3. Elegir herramienta
↓
6. Documentar ← 5. Evaluar y analizar errores ← 4. Implementar

El paso que más se salta es el **5**: mirar los errores, no solo la métrica.

La progresión de los notebooks

Notebook	Construye	Representación
N01	Tokenizar, BoW, tf-idf	Cuenta de palabras
N02	Clasificador con PyTorch	<i>Word embeddings</i>
N03	Afinar DistilBERT	<i>Embeddings</i> contextuales
N04	<i>Pipeline</i> de spaCy	Modelo preentrenado

Y los cuatro entregables aplican cada nivel a un problema propio: **EX1** representación · **EX2** clasificador · **EX3** *transfer learning* · **EX4** asistente de punta a punta.

Ejemplo guiado: clasificador de reseñas

1 clasificar positiva/negativa · **2** 60 reseñas anotadas · **3** tf-idf, no *transformer* · **4** `TfidfVectorizer` → `LogisticRegression` · **5** exactitud + leer 2 errores · **6** documentar origen y límites.

La herramienta se elige por los datos que hay, no por lo moderna que sea.

Cierre

Puntos clave (I)

- El PLN combina lingüística, estadística y aprendizaje profundo para que las máquinas comprendan y se comuniquen con el lenguaje humano.
- El potencial es alto y medible: SQuAD supera al humano, sentimiento al 95-97 %.
- La **ambigüedad** tiene seis formas y **no se elimina: se decide** con el contexto.
- El **POS tagging** desambigua categorías; el *tagset* es un compromiso información/dificultad.
- Sesgos, falta de comprensión, lenguas con pocos recursos e ironía son limitaciones reales.

Puntos clave (II)

- El **AI Act** es una herramienta de diseño: bajo riesgo (considerando 53) y prohibiciones (artículo 5).
- El **lingüista** diseña el *tagset* y anota; **las anotaciones deciden las predicciones**.
- La **cooperación** se evalúa: NLLB y Masakhane frente a la investigación paracaidista.
- **NLTK para aprender, spaCy para producir**; la herramienta se elige por los datos que hay.
- Construir un sistema son **seis pasos**, y el que más se salta es **mirar los errores**.

Cómo se evalúa

Peso	Instrumento
40 %	Media de los cinco entregables (EX1 , EX2 , EX2.5 , EX3 , EX4)
60 %	Prueba del RA3: test y desarrollo sobre el contenido de la unidad

EX2 y EX4 llevan una **parte escrita** que cubre RA3-b, RA3-e y RA3-f. **Cuenta.**

La normativa exige alcanzar todos los RA; el centro lo concreta en **≥ 5 en cada uno.**

¿Y ahora?

El lenguaje es la interfaz más natural entre personas y máquinas — y la más ambigua.

A construir un sistema que la resuelva.